Manipulación de data.frame con dplyr

Luciano Selzer

21 September, 2016

La manipulación de datos es una de las operaciones más comunes:

- seleccionar observaciones
- seleccionar variables
- agrupar por características
- calcular estadísticas

Podemos hacerlo en R base:

```
mean(gapminder[gapminder$continent == "Africa",
```

```
[1] 2193.755
```

```
mean(gapminder[gapminder$continent == "Americas"
```

```
[1] 7136.11
```

```
mean(gapminder[gapminder$continent == "Asia", "g
```

```
[1] 7902.15
```

Pero lleva mucha repetición

El paquete `dplyr`

El paquete `dplyr` tiene varias funciones útiles que:

- Reducen la repetición
- Reducen la probabilidad de cometer errores
- Reducen la cantidad de tipeo
- Es más fácil de leer

Vamos a usar las 6 más comunes y también el *pipe* (tubo) (`%>%`) para combinarlas:

1. `select()`
2. `filter()`
3. `group_by()`
4. `summarize()`
5. `mutate()`

Si no lo han instalado antes, háganlo con:

```
install.packages('dplyr')
```

Y carguen el paquete:

```
library(dplyr)
```

Usando select()

Seleccionar variables

```
year_country_gdp <- select(gapminder,year,countr
```

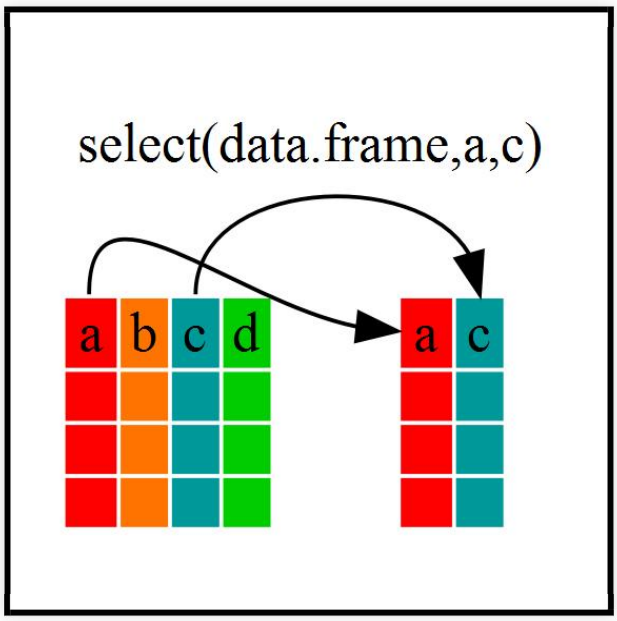

7

El verdadero poder aparece usando los pipes

```
year_country_gdp <- gapminder %>% select(year,co
```

¿Cómo funcionan los pipes?

Usando filter()

Podemos filtrar usando `filter()`

```
year_country_gdp_euro <- gapminder %>%
    filter(continent == "Europe") %>%
    select(year, country, gdpPercap)
```

Ejercicio 1

Escribe en una sola operación (que puede tener varias lineas e incluir pipes) que produzca un data.frame que tenga los valores de África para `lifeExp`, `country` y `year`, pero no otros continentes.

¿Cuántas filas tiene tu data.frame? ¿Por qué?

Usando group_by() y summarize()

Podemos definir variables de agrupación usando

`group_by()`

```
str(gapminder)
```

```
'data.frame':   1704 obs. of  6 variables:
 $ country  : Factor w/ 142 levels "Afghanistan"
 $ year     : int  1952 1957 1962 1967 1972 1977
 $ pop      : num  8425333 9240934 10267083 1153
 $ continent: Factor w/ 5 levels "Africa","Ameri
 $ lifeExp  : num  28.8 30.3 32 34 36.1 ...
 $ gdpPercap: num  779 821 853 836 740 ...
```

```
str(gapminder %>% group_by(continent))
```

```
Classes 'grouped_df', 'tbl_df', 'tbl' and 'data.
 $ country  : Factor w/ 142 levels "Afghanistan"
 $ year     : int  1952 1957 1962 1967 1972 1977
 $ pop      : num  8425333 9240934 10267083 1153
 $ continent: Factor w/ 5 levels "Africa","Ameri
 $ lifeExp  : num  28.8 30.3 32 34 36.1 ...
 $ gdpPercap: num  779 821 853 836 740 ...
 - attr(*, "vars")=List of 1
  ..$ : symbol continent
 - attr(*, "drop")= logi TRUE
 - attr(*, "indices")=List of 5
```

La estructura no es igual que en original.
Una `list` que contiene las filas que corresponden a un continente en particular.

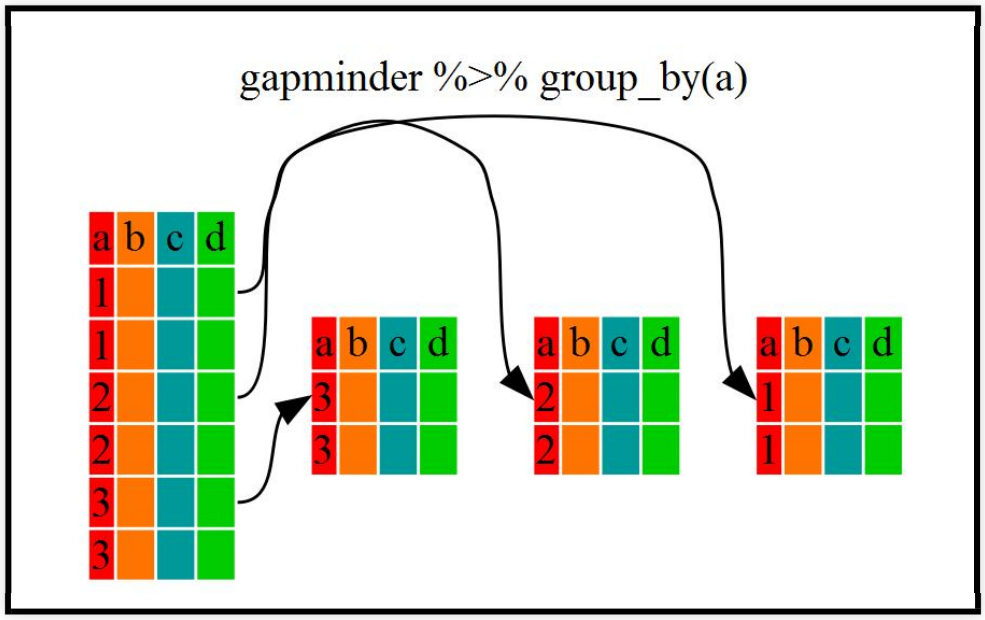
gapminder %>% group_by(a)
a b c d
1
1
2
2
3
3
a b c d
3
3
a b c d
2
2
a b c d
1
1

Usando summarize()

`group_by()` no es muy interesante por si solo. Es más interesante de usar con `summarize()`. Esto nos permite usar otras funciones como `mean` o `sd` de forma similar a `plyr`

```
gdp_bycontinents <- gapminder %>%
    group_by(continent) %>%
    summarize(mean_gdpPercap = mean(gdpPercap))
```

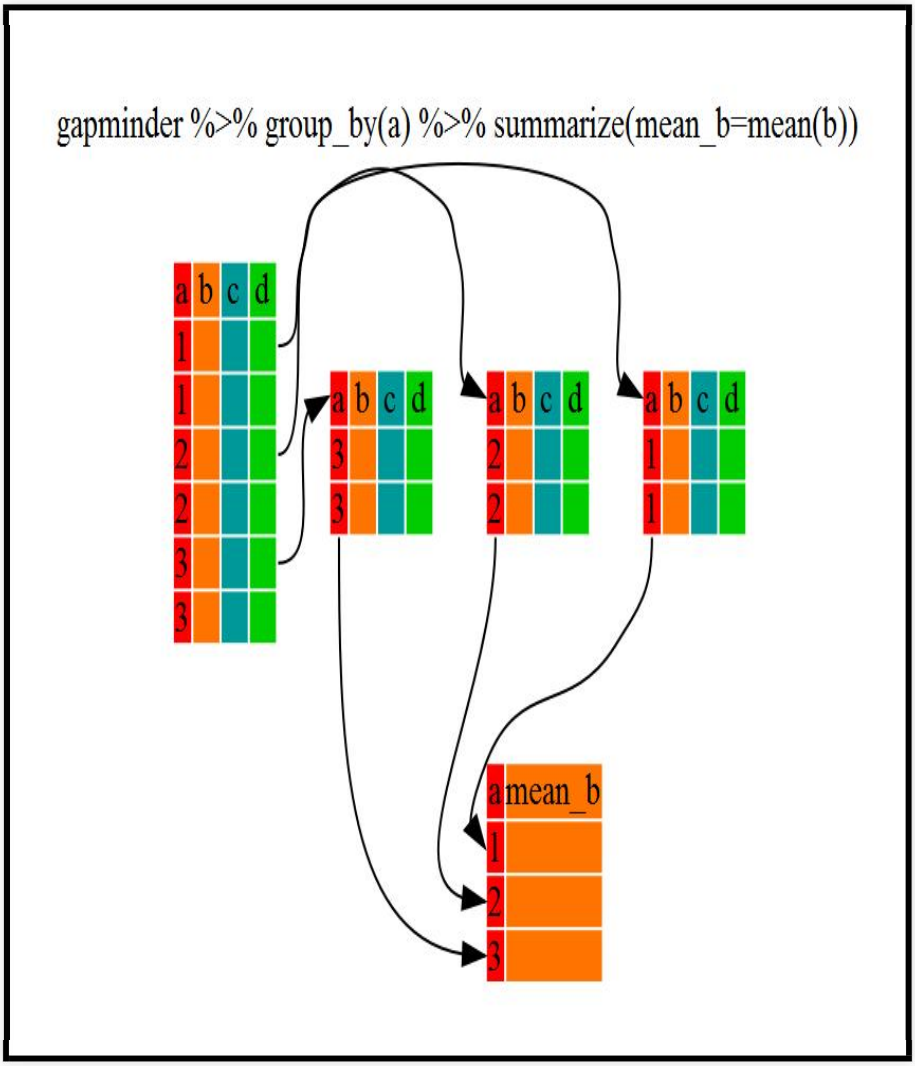
gapminder %>% group_by(a) %>% summarize(mean_b=mean(b))
a b c d
1
1
2
2
3
3
a b c d
3
3
a b c d
2
2
a b c d
1
1
a mean_b
1
2
3

Ejercicio 2

Calcula la expectativa de vida promedio por país ¿Cuál tiene la mayor?¿Y cuál la menor?

Nos permite calcular la media de PBI por continente pero se pueden hacer más cosas. También podemos agrupar por varias variables. Por ejemplo `year` y `continent`.

```
gdp_bycontinents_byyear <- gapminder %>%
    group_by(continent, year) %>%
    summarize(mean_gdpPercap = mean(gdpPercap))
```

Eso de por si es bastante útil, pero además podemos calcular ¡varias variables por vez!

```
gdp_pop_bycontinents_byyear <- gapminder %>%
    group_by(continent, year) %>%
    summarize(mean_gdpPercap = mean(gdpPercap),
              sd_gdpPercap = sd(gdpPercap),
              mean_pop = mean(pop),
              sd_pop = sd(pop))
```

Usando mutate()

Podemos crear nuevas antes de (o incluso después) de resumir la información usando `mutate()`.

```
gdp_pop_bycontinents_byyear <- gapminder %>%
    mutate(gdp_billion = gdpPercap*pop/10^9) %>%
    group_by(continent,year) %>%
    summarize(mean_gdpPercap = mean(gdpPercap),
              sd_gdpPercap = sd(gdpPercap),
              mean_pop = mean(pop),
              sd_pop = sd(pop),
              mean_gdp_billion = mean(gdp_billio
              sd_gdp_billion = sd(gdp_billion))
```

Ejercicio Avanzdo

Calcula la expectativa de vida promedio en 2002 para dos países seleccionados al azar de cada continente. Luego ordena los nombres de los continentes en el orden inverso a la expectativa de vida.

Pista: usa las funciones de `dplyr`, `arrange()` y `sample_n()`, tienen una sintaxis similar a otras funciones del paquete.

Otros recursos muy buenos

- Data Wrangling Cheat sheet
- Introduction to dplyr